

---

## TP 2 : Fonction de répartition, loi binomiale et régression

---

### Exercice 2.1 —

1) En utilisant des fonctions déjà implémentées dans R, tracez la fonction de répartition des lois suivantes (Indication : utilisez le type 's' pour les courbes). Vous pouvez choisir d'utiliser soit `pXXXX` avec `XXXX` le nom de la loi soit `cumsum` pour certains appels à `choose` :

- Une loi binomiale de paramètre  $n = 10$  et  $p = 0.5$ ,
- Une loi de Bernoulli de paramètre  $p = 0.4$ ,
- Une loi hypergéométrique de paramètre :  $m = 15$ ,  $n = 11$  et  $k = 6$ .

### Exercice 2.2 —

1) Calculer les probabilités  $P(X = k)$  lorsque la loi de  $X$  est la loi binomiale de paramètres  $n = 15$  et  $p = 0.3$  (*Vous pourriez utiliser la fonction `dbinom`*).

2) Représenter la loi de  $X$  à l'aide d'un diagramme bâton `barplot(D)`.

3) Quelle est la valeur la plus probable (c'est le mode de la distribution).

4) Calculer la probabilité des événements suivants :

- $[X \leq 10]$
- $[X \geq 4]$
- $[3 \leq X \leq 9]$

5) Soit  $Y = X|X \geq 3$ , c'est-à-dire,  $P(Y = k) = \frac{P(X = k, X \geq 3)}{P(X \geq 3)}$ . Créez un vecteur représentant les valeurs  $P(Y = k)$  pour  $Y = 0, \dots, 15$ .

6) Calculez la moyenne et la variance de  $X$  ainsi que de  $Y$ .

7) Calculez et représentez la fonction de répartition de  $Y$ .

**Exercice 2.3 —** (CC 1 2014-2015) Dans un bassin, il y a un nombre inconnu  $N$  de poissons. Pour estimer le nombre, on capture  $n < N$  poissons (sans remise) et on les remet à l'eau après avoir marqués. Puis, on capture à nouveau  $k$  poissons (toujours sans remise). On s'intéresse à la probabilité de l'événement  $A = \{\text{"il y a 3 poissons marqués lors de la deuxième capture"}\}$ . Fixons  $n = 10$  et  $k = 5$ .

1) Pour  $N = 30$ , calculer la probabilité de  $A$ .

2) Dessiner  $P(A)$  en fonction de  $N$  entre 10 et 100 par pas de 1. Pour quelles valeurs  $N$ ,  $P(A)$  atteint-il son maximum ?

3) Même question pour  $(n, k) = (10, 10)$  et  $(n, k) = (10, 20)$ . (Si vous voyez un message d'avis d'avis, expliquez pourquoi).

4) C'est quoi le lien entre le  $N$  que vous avez trouvé et la proportion de poisson marqués trouvés dans l'échantillon de  $k$  poissons ?

#### Exercice 2.4 —

- 1) Entrez dans R le vecteur  $X$  composé de tous les entiers de 1 à 100.
- 2) Tracez le nuage de points entre les vecteurs  $X$  et  $Y = 2X$  ainsi que  $Z = -3X$ .
- 3) Calculez le coefficient de corrélation entre  $X$  et  $Y = \sqrt{X}$ .
- 4) Retrouvez un vecteur  $U$  qui donne les premiers 100 nombres de la suite de Fibonacci. Calculez la coefficient de corrélation entre  $X = \text{seq}(1, 100, 1)$  et  $Y = \log(U)$ .
- 5) Pour chacun des exemples ci-dessus, tapez les commandes

```
reg = lm(Y~X)
plot(X,Y)
abline(reg)
```

Que remarquez-vous ?

#### Exercice 2.5 — Introduction aux tableaux de données

Un tableau est une structure de R qui regroupe des objets pouvant être des vecteurs, des valeurs numériques ou des caractères. Beaucoup de tableaux sont déjà chargés dans R.

- 1) Tapez la commande `data()` pour voir les tableaux déjà chargés dans R.
- 2) Si le tableau `trees` n'y est pas, chargez le via la commande `data(trees)` et examiner les résultats des deux commandes de R `str(trees)` et `summary(trees)`
- 3) Extrayez le vecteur composé des valeurs `Girth` (diamètre) du tableau en utilisant `trees$Girth` ou `trees[, 1]`
- 4) Que se passe-t-il si vous utilisez la fonction `plot` sur le tableau `trees`: `plot(trees)`
- 5) Calculez les coefficients de corrélation entre les différentes colonnes du tableau `trees`, et vérifier que les résultats sont les mêmes que ceux donnés par la commande `cor(trees)`

#### Exercice 2.6 — On utilise le tableau de données `trees`.

- 1) Entrez dans un vecteur  $X$  le diamètre des arbres. Dans un vecteur  $Y$  leur volume.
- 2) Tracer le nuage de points représentant le volume des arbres en fonction de leur grosseur. Ne fermez pas le graphe.
- 3) Entrez les commandes :

```
reg=lm(Y~X)
reg
abline(reg)
```

Que remarquez-vous ? Quel est le coefficient directeur de la droite tracée ? ( Tapez `coef(reg)` ou `summary(reg)` pour le retrouver). Il doit être proche (sans être égal) à celui de la droite de régression linéaire  $y - E(Y) = \frac{\text{cov}(X, Y)}{\text{var}(X)}(x - E(X))$ . Calculez  $\frac{\text{cov}(X, Y)}{\text{var}(X)}$ .

- 4) Refaites la même chose mais cette fois-ci avec le volume en fonction de la taille.
- 5) Commentez les différents résultats obtenus.